

项目：Hi-Loc (Hybrid Indoor Localization via Enhanced 5G NR CSI) 复现

论文链接：<https://ieeexplore.ieee.org/document/9855525>

本项目在 CPU 上运行，依赖的库有 torch、numpy、scipy、pyyaml、tqdm、matplotlib、scikit-learn 等。

依次运行 train.py、test.py、infer.py 即可，缓存数据存储在 data/cache 中，训练好的模型存储在 checkpoints，其余结构存储在 outputs 中。

目录

1	总体流程.....	1
2	数据与预处理.....	2
1.1	数据来源	2
2.1	数据结构	2
3	方法.....	4
3.1	CFR 表示与统一化	4
3.2	特征增强	4
3.3	多基站融合	5
3.4	序列构建	5
3.5	基线网络：CNN→BiLSTM→FCRegression	6
3.6	Feature Attention.....	6
3.7	数据缓存与样本元信息	7
4	实验设计.....	7
4.1	数据集划分	7
4.2	训练配置	7
4.3	评估指标与输出	7
4.4	消融实验	8
5	结果与分析.....	8
5.1	训练/验证损失曲线.....	8
5.2	测试误差	9
5.3	测试误差直方图	10

5.4	真实值 vs 预测散点图	11
5.5	结论	12
6	消融实验结果分析	12
6.1	结构层消融实验	12
6.2	特征层消融	13
6.3	训练策略层消融	14
7	结论与改进方向	15
7.1	复现度总结	15
7.2	不足之处	15
7.3	实验总结	15

1 总体流程




图 1 论文流程

本项目复现了论文中的核心时空建模主干，即 CNN-BiLSTM-FC。其中，CNN 用于提取局部特征，BiLSTM 用于建模时序依赖，最后通过全连接层回归终端二维位置。在此基础上，工程中进一步加入了可选的 Feature Attention 模块以及 LayerNorm、Dropout 等稳定化设计。受限于硬件设备，项目未完整实现论文中的 Sample Attention 和更完整的端到端 Hi-Loc 结构。



图 2 本项目模型结构

2 数据与预处理

1.1 数据来源

无线网络真实数据开放平台 http://www.pmlatanet.com.cn/dataapp/5G-A_positioning_dataset_for_AI 的虚拟仿真数据。

2.1 数据结构

仿真数据集中包含 InF-SL、InF-DL、InF-SH、InF-SL 四种室内信道场量的精确模型。每种场景都配置了 0ns、2ns、10ns、50ns 四种不同等级的时序偏差，共形成 16 中差异化的仿真环境。

参数类型	参数配置
信道模型	InF-SL(Sparse-clutter,LowBS)
	InF-DL(Dense-clutter,LowBS)
	InF-SH(Sparse-clutter,HighBS)
	InF-DH(Dense-clutter,HighBS)

大厅尺寸	InF-SL:120x60m InF-DL:300x150m InF-SH:300x150m InF-DH:120x60m
BS 位置	18 个基站分布在距离为 D 的方阵上，距离墙壁为 D/2。-对于较小面积的厅(L=120mxW=60m):D=20m-对于较大面积的厅(L=300mxW=150m):D=50m
天线配置	gNB:(M,N)=(4,4)UE:(M,N)=(1,2)
UE 天线高度	1.5m
gNB 天线高度	InF-SH,InF-DH:8m InF-SL,InF-DL:1.5m
载波频率	3.5GHz
带宽	100MHz
子载波间隔	30kHzfor100MHz
网络同步误差	对于每次撒点，定义为一个基站和一个假定有完美定时的定时参考源之间的(T1ns)均方根值的随机高斯分布，以最大的时间差 T2ns 为准，其中 $T2=2*T1-T1:0ns(完全同步),2ns,10ns,50ns$

数据文件夹结构：

```

Simulated_DataSet/
├── InF_DH/
│   ├── sync_err_0/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_2/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_10/CFR1, ..., CFR18, UE_pos
│   └── sync_err_50/CFR1, ..., CFR18, UE_pos
├── InF_DL/
│   ├── sync_err_0/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_2/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_10/CFR1, ..., CFR18, UE_pos
│   └── sync_err_50/CFR1, ..., CFR18, UE_pos
├── InF_SH/
│   ├── sync_err_0/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_2/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_10/CFR1, ..., CFR18, UE_pos
│   └── sync_err_50/CFR1, ..., CFR18, UE_pos
├── InF_SL/
│   ├── sync_err_0/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_2/CFR1, ..., CFR18, UE_pos
│   ├── sync_err_10/CFR1, ..., CFR18, UE_pos
│   └── sync_err_50/CFR1, ..., CFR18, UE_pos
└── README.md

```

受限于计算机算力，本次复现仅使用 InF_DH 和 InF_DL 中 sync_err_0、sync_err_10、sync_err_50 的数据。

3 方法

整体流程为：从每个基站的 CFR 原始复数张量出发，进行特征增强（频域降采样+统计特征），构建固定长度时序序列后，输入深度网络（CNN→BiLSTM→FC），输出用户二维位置 (x,y) 。在多基站场景中，对各基站特征进行拼接形成联合特征输入；并引入输入归一化与正则化稳定训练；在此基础上提供可配置的 FeatureAttention 模块。方法实现见数据处理模块 loader.py、feature_engineering.py、sequence_builder.py 与模型模块 baseline_models.py。

3.1 CFR 表示与统一化

原始数据以.mat 文件存储。每个基站的 CFR 文件记为 CFRk.mat ($k \in \{1, \dots, 18\}$)，用户位置标签为 UE_pos.mat。为了兼容 MATLABv7.3 (HDF5) 与传统 MAT 文件，项目使用自动读取器 load_mat_auto()读取数据，同时对常见转置存储进行修正，实现见 loader.py。

在实际数据中，单样本 CFR 并非一维子载波向量，而是多维复数张量，实测形状为(2,16,3264)。为统一特征工程输入形式，项目将 CFR 在“非子载波维”上做均值聚合，得到长度为 3264 的复数向量：

$$h \in \mathbb{C}^{N_{sc}}, h[n] = \text{mean}_{\text{axes} \setminus \text{neqsc}}(\text{CFR}[:, :, n])$$

实现见 feature_engineering.py。

3.2 特征增强

对每条 CFR 复数向量 h 构造增强特征 f ，包含两部分：

- (1) 频域降采样特征（408 维）

以步长 $r=8$ 进行频域等间隔采样：

$$h_{ds} = h[0:r:N_{sc} - 1], \quad |h_{ds}| \in \mathbb{R}^{408}$$

为保持维度为 $408+8=416$ ，项目取降采样后幅度 $|h_{ds}|$ 作为频域特征。实现见 feature_engineering.py。

(2) 幅度统计特征 (8 维)

对完整幅度向量 $a = |h|$ 计算 8 个统计量:

- 均值 μ 、标准差 σ 、最大值、最小值
- 偏度 (skewness)、峰度 (kurtosis)
- 能量: $\sum_i a_i^2$
- 熵: 令 $p_i = \frac{a_i}{\sum_j a_j + \epsilon}$, 则 $H(a) = -\sum_i p_i \log(p_i + \epsilon)$ 。实现见 `feature_engineering.py`。

最终每个基站每个样本的增强特征为:

$$f^{(bs)} = [|h_{ds}|, \text{stats}(a)] \in \mathbb{R}^{416}$$

3.3 多基站融合

设使用 G 个基站 (本项目中 $G=18$), 对同一时刻的各基站增强特征在特征维进行拼接:

$$f = [f^{(1)}, f^{(2)}, \dots, f^{(G)}] \in \mathbb{R}^{416G}$$

实现逻辑为逐基站读取 `CFRk.mat`, 分别提取特征后 `np.concatenate(axis=1)` 得到 X_{raw} , 见 `loader.py`。输入维度由运行时根据 `base_station_ids` 自动计算:

$$F = 416 \times \text{times}G$$

实现见 `runtime.py`。

3.4 序列构建

对独立样本特征矩阵 $X \in \mathbb{R}^{N \times F}$ 与标签 $Y \in \mathbb{R}^{N \times 2}$, 采用滑动窗口构建长度 $T=5$ 的序列:

$$X_i = X[i:i+T], \quad y_i = Y[i+T-1]$$

滑动步长为 `step=2`, 从而生成:

$$X_{\text{seq}} \in \mathbb{R}^{N_{\text{seq}} \times T \times F}, \quad Y_{\text{seq}} \in \mathbb{R}^{N_{\text{seq}} \times 2}$$

实现见 `sequence_builder.py`。标签取窗口最后一帧对应的 (x, y) (即“预测当前/最新位置”)。

3.5 基线网络：CNN→BiLSTM→FCRegression

令网络输入为 $X \in \mathbb{R}^{\mathbb{B} \times T \times \mathbb{F}}$ 。

(1) 输入归一化与 Dropout

对每个时间步在特征维做 LayerNorm，并施加 Dropout：

实现见 `baseline_models.py`。

(2) CNN 时域局部模式提取

将输入转置为 Conv1d 所需格式 (B, F, T) ，使用两层 1D 卷积（核大小 3，padding 保持 T 不变），每层后接 BatchNorm 与 ReLU：

$$(B, F, T) \xrightarrow{\text{Conv1d}} (B, C, T)$$

实现见 `cnn_block.py`，调用见 `baseline_models.py`。

(3) BiLSTM 时序建模

将 CNN 输出转置回 (B, T, C) ，输入双向 LSTM：

$$(B, T, C) \xrightarrow{\text{BiLSTM}} (B, T, 2H)$$

其中 H 为隐藏层维度。实现见 `bilstm_block.py`，调用见 `baseline_models.py`。

(4) 回归输出

取最后时间步表示 $z = X[:, T-1, :] \in \mathbb{R}^{\mathbb{B} \times 2\mathbb{H}}$ ，经两层全连接回归到二维坐标：

$$\hat{y} \in \mathbb{R}^{\mathbb{B} \times 2}$$

实现见 `baseline_models.py`。

3.6 Feature Attention

为增强对关键特征维的选择性，本项目实现了时间步级的 Feature Attention：对每个时间步的特征向量 $x_t \in \mathbb{R}^{\mathbb{F}}$ 通过两层 MLP 生成门控权重 $w_t \in (0,1)^{\mathbb{F}}$ ，并进行逐元素重标定： $w_t = \sigma(W_{2\text{ReLU}}(W_1 x_t))$ ， $\tilde{x}_t = x_t \odot w_t$ 。实现见 `feature_attention.py`。在本项目中该模块插入在 CNN 输出与 BiLSTM 之间（即在 (B, T, C) 上进行），见 `baseline_models.py`。是否启用由配置项 `model.use_feature_attention` 控制（见 `runtime.py`）。

3.7 数据缓存与样本元信息

由于.mat 文件体积较大，项目在首次预处理后将序列化特征与标签缓存为.npy 文件： X_{seq} ， Y_{seq} 。

缓存命名包含场景、同步误差与基站范围（如 bs1to18），见 loader.py。此外，为支持后续可解释性分析与固定测试集审计，数据集为每个序列样本生成 metadata（场景、同步误差、序列起止索引等），见 loader.py。

4 实验设计

4.1 数据集划分

数据集划分：train=0.7、val=0.15、test=0.15，随机种子 seed=42。

导出划分清单：

outputs/splits/train_manifest.csv/val_manifest.csv/test_manifest.csv，可追溯每个样本来自哪个场景与同步误差。

4.2 训练配置

优化器：Adam，学习率 lr=3e-4，权重衰减 weight_decay=1e-4，batchsize32，最多 50epoch。

损失函数：MSE。

早停：验证集若连续 10 个 epoch 无提升则停止；最佳模型保存为 checkpoints/best_model.pt。

4.3 评估指标与输出

指标：TestMSE、RMSE、MAE、MeanDistanceError，并统计误差分位数 P50/P90/P95。见 test.py。

输出文件：

- outputs/test/metrics.json（指标）
- outputs/test/predictions.csv（逐样本预测）
- outputs/test/error_histogram.png、error_cdf.png、prediction_scatter.png（可视化）


训练曲线输出：outputs/train/loss_curve.png 与 loss_history.json，见 trainer.py。

4.4 消融实验

移除一些变量，判断对实验结果的影响。

5 结果与分析

5.1 训练/验证损失曲线




前期 trainloss 和 valloss 都快速下降，说明模型确实学到了有效特征，不是完全没收敛。中后期两条曲线整体接近，没有出现明显“训练集继续下降、验证集明显上升”的严重过拟合，这说明当前这版训练策略是比较稳定的。

验证损失在后半段仍有小幅波动，但最佳点出现在较靠后的 epoch，这和 checkpoint_epoch=45 一致，说明模型提升是渐进的。

结论：训练过程是健康的，当前主要问题不是收敛失败，而是模型表达能力和预测分布还存在偏差。

5.2 测试误差



曲线前半段上升较快，说明有相当一部分样本误差集中在较低区间。

结合 `metrics.json`：

$P50 \approx 39.85$ ，表示约一半样本误差小于 40


$P90 \approx 93.16$ ，表示约 90% 样本误差小于 93

$P95 \approx 116.69$ ，表示还有一部分长尾样本误差较大

曲线在 100 以后明显变平，说明后面进入“难样本区域”，模型对这部分样本定位不够稳定。长尾效应可能的原因有：边缘区域 UE 采样稀疏、多基站同步偏差累积、复杂室内遮挡信道畸变；模型偏向学习中心区域特征，对边界稀有样本泛化能力不足。

结论：整体可用，但长尾误差仍然明显，存在可优化空间。

5.3 测试误差直方图



大多数样本集中在大约 20~60 的误差区间，这和 `mean_distance_error=49.56`、`P50=39.85` 是一致的。

右侧拖着长尾，延伸到 100+甚至更高，说明模型在部分样本上会出现较大的预测偏差。

结论：模型不是“整体都差”，而是“多数样本中等可接受，少数样本很差”。

5.4 真实值 vs 预测散点图



蓝色真实点覆盖范围很广，说明测试集位置分布比较分散。

橙色预测点没有覆盖真实分布的全区域，而是明显集中在一条较窄的带状/斜线区域内，尤其：

- Y 方向预测范围明显被压缩
- X 方向虽然有变化，但预测点仍然更集中

这说明模型存在一种“回归到常见区域/均值流形”的倾向，也就是：

- 模型能学到总体趋势
- 但对复杂空间分布的表达不足
- 对边缘区域、稀疏区域或困难样本容易预测到“常见位置附近”

结论：当前模型已经能抓住粗略空间结构，但定位结果仍有明显“分布塌

缩”现象。

5.5 结论

综合以上分析，当前模型训练是稳定的，说明工程实现和优化策略基本有效。模型已经学到“整体趋势”，但在“更精细的空间区分能力”方面依然欠佳。

6 消融实验结果分析

6.1 结构层消融实验

为了检验模型性能的提升是否是由设计的网络结构带来的，接下来进行结构层的消融实验：

单基站基线：1 BS + CNN + BiLSTM + FC

多基站基线：18 BS + CNN + BiLSTM + FC

多基站+稳定化策略：18 BS + LayerNorm + Dropout + weight decay + grad clip + CNN + BiLSTM + FC

模型版本	实验设置	Checkpoint Epoch	Val Loss	Test RMSE	Test MAE	Mean Distance Error
单基站基线	单基站，早期小范围数据	10	694.6184	37.1504	21.5214	33.9404
多基站直接拼接	18 基站拼接，无稳定化	2	4186.5272	88.7258	47.6224	76.1624
多基站 + 稳定化策略	18 基站拼接 + 归一化 / 正则化	47	1739.9996	58.4582	30.7152	47.9424

表中给出了单基站基线、多基站直接拼接以及多基站结合稳定化策略三种方案的实验结果。从整体上看，这三组结果较清晰地反映了本项目从基础可运行版本到稳定多基站模型的演进过程。

首先，单基站基线取得了当前表中最好的数值结果，即 Test RMSE = 37.1504，Mean Distance Error = 33.9404。这说明在较简单设置下，单基站输入已经能够为模型提供一定的定位信息，也证明了当前构建的数据读取、特征工

程、序列建模与回归预测链路是有效的。

其次，当模型输入从单基站扩展为多基站直接拼接后，实验结果出现了明显下降。该方案的 Test RMSE 上升至 88.7258，Mean Distance Error 上升至 76.1624，同时最佳模型仅出现在第 2 个 epoch，对应的验证损失也高达 4186.5272。这说明虽然多基站带来了更丰富的空间信息，但简单地对 18 个基站特征进行高维拼接，会显著增加输入维度和模型优化难度，从而导致训练过程不稳定，并使模型更容易发生过拟合。

在此基础上，引入输入归一化、Dropout、权重衰减、梯度裁剪和较低学习率等稳定化策略之后，多基站模型性能得到明显改善。该方案的 Test RMSE 降至 58.4582，Mean Distance Error 降至 47.9424，相比直接多基站拼接有大幅提升；同时其最佳模型出现在第 47 个 epoch，对应验证损失降低至 1739.9996。这说明稳定化策略有效缓解了高维输入带来的训练不稳定问题，使模型能够更充分地从多基站特征中学习有效信息。

若将后两组多基站方案进行直接比较，可以发现性能退化的主要原因并非来自多基站信息本身，而是来自高维输入条件下训练配置不合理。这组对比实验说明了稳定化策略的有效性。

6.2 特征层消融

为验证不同特征组成对定位性能的影响，在统一的多基站稳定训练框架下，对“仅降采样特征”“仅统计特征”以及“降采样+统计特征”三种方案进行了对比：

仅降采样特征：每基站 408 维

仅统计特征：每基站 8 维

降采样+统计特征：每基站 416 维

特征方案	Checkpoint Epoch	Val Loss	Test RMSE	Test MAE	Mean Distance Error	P50	P90	P95
仅降采样特征	44	1515.5729	59.6090	27.2785	44.3092	29.9609	105.7032	133.6433
降采样 + 统计特征	47	1739.9996	58.4582	30.7152	47.9424	39.2093	92.6887	117.6327
仅统计特征	47	2009.5825	64.1203	33.6357	52.7727	43.8304	105.9875	124.6558

实验结果表明，仅统计特征方案性能最弱，说明均值、方差、偏度、峰度、能量和熵等全局统计量不足以完整表征定位任务所需的细粒度信道信息。相比之下，仅降采样特征已经能够取得较好的定位性能，说明降采样后的频域幅度

特征是当前模型最主要的信息来源。

进一步地，降采样与统计特征结合后，模型在 RMSE 以及高分位误差（P90、P95）上取得了最佳结果，说明统计特征虽然不能单独支撑定位任务，但能够作为补充信息改善模型对困难样本和长尾误差的处理能力。

综合来看，频域降采样特征构成了定位模型的主体信息，而统计特征的主要作用在于增强模型对复杂样本的鲁棒性。因此，当前采用的“降采样+统计特征”方案仍然是较为合理的综合设计。

6.3 训练策略层消融

方案设计

方案	输入归一化	Dropout	lr	weight decay	grad clip
无稳定化	否	否	0.001	0	无
仅归一化 + Dropout	是	是	0.001	0	无
仅优化层稳定化	否	否	0.0003	0.0001	1.0
完整稳定化	是	是	0.0003	0.0001	1.0

实验结果

方案	Checkpoint Epoch	Val Loss	Test RMSE	Test MAE	Mean Distance Error	P50	P90	P95
无稳定化	2	4186.5272	88.7258	47.6224	76.1624	69.5584	144.6768	168.5097
仅归一化 + Dropout	46	1105.1378	48.2837	21.4711	34.3002	22.8464	80.2004	103.8563
仅优化层稳定化	7	3540.3303	83.6736	48.5089	76.7163	75.5826	121.1417	134.1356
完整稳定化	47	1739.9996	58.4582	30.7152	47.9424	39.2093	92.6887	117.6327

实验结果表明，输入归一化与 Dropout 是当前多基站模型中最关键的稳定化策略。在四组实验中，“仅归一化+Dropout”取得了最好的结果，说明多基站高维输入带来的主要问题是特征分布不稳定和过拟合，而不是单纯的优化器设置问题。

相比之下，“仅优化层稳定化”虽然引入了更小的学习率、权重衰减和梯度裁剪，但性能提升非常有限，说明仅依靠优化层面的调整不足以从根本上解决问题。完整稳定化策略整体优于无稳定化和仅优化层稳定化，但其结果仍未超过“仅归一化+Dropout”，说明不同稳定化策略之间仍存在进一步调优空间。

总体来看，这组实验说明：多基站模型训练的关键首先在于稳定输入分布和抑制过拟合，其次才是优化层面的精细调整。

7 结论与改进方向

7.1 复现度总结

本项目较完整地复现了论文的核心流程：原始 CFR 预处理、特征增强、滑动窗口序列构建、CNN-BiLSTM 主干建模以及坐标回归。且当前复现结果与论文总体一致。

但是从“严格一比一结构复刻”角度看，本项目仍属于“核心思想复现 + 工程化实现”，而非对论文全部模块的逐层完全照搬。当前工程重点落在 CNN-BiLSTM 主干、多基站扩展和训练稳定化，部分论文中的完整注意力链路尚未全部原样重建。

7.2 不足之处

当前训练主要在 CPU 环境下完成，训练速度和大规模超参数搜索能力都收到明显限制。本项目使用的仿真数据集与真实商业 5G 网络环境仍存在差异。模型层面，对目前已经验证了特征层和训练层的部分关键因素，但对结构层的完整对比仍可继续优化。此外当前结果是单一数据源条件下的位置回归能力，对于跨场景泛化、跨同步误差鲁棒性，跨设备迁移能力，还缺少更系统的验证。

7.3 实验总结

综上，本项目较为完整地复现了 Hi-Loc 论文的核心技术路线，并在多基站扩展、结果可视化和消融实验方面进行了进一步工程化验证。实验结果表明，融合特征在总体性能和长尾误差控制上优于单一特征，这与原论文的主要趋势保持一致。与此同时，当前工作也暴露出若干限制，包括 CPU 训练条件下实验规模受限、仿真数据与真实商用 5G 信号之间仍存在差异，以及复杂 NLOS 环境建模仍有提升空间。后续将围绕超参数优化、更完整的注意力结构设计、跨场景泛化验证以及与 PDR/IMU 等多源信息融合展开深入研究，以进一步提升室内定位系统的精度、稳定性与实际应用价值。